

Plan de Investigación

Programa de Doctorado: [Lenguas, Literaturas y Culturas, y sus Aplicaciones](#) **Departamento:** [Departamento de Lingüística Aplicada — Universitat Politècnica de València \(UPV\)](#) **Doctoranda:** [Ana Eslava-Graterol](#)
Directora: [Prof.^a M^a Luisa Carrió-Pastor \(Dept. de Lingüística Aplicada, UPV\)](#) **Codirector:** [Prof. Ricardo Casañ-Pitarch \(Dept. de Lingüística Aplicada, UPV\)](#) **Fecha:** 08/08/2026 · **Modalidad/duración:** [\[tiempo completo 3 años / parcial 5 años — a confirmar\]](#)

Guía de lectura. Este plan sigue la plantilla de nueve apartados de la UPV. Desarrolla un entorno — **MLLDE (Mobile Language Learning Design Environment)**: un entorno de diseño y medición para aplicaciones de aprendizaje de lenguas mobile-native — apps concebidas primero para el móvil (PWA con soporte sin conexión, lecciones breves, tutoría conversacional con IA), no e-learning de escritorio reducido a una pantalla. MLLDE plantea dos aportaciones: ① **escritura / alfabetización en IA** (que extiende el Objetivo 4 del TFM de la doctoranda, instanciado en Academic Writing Journey) y ② **habla / pronunciación** (Architecture Voice Design + un Measurement Module medible acústicamente y alineado al MCER en xAPI). Un prototipo gamificado mobile-native es la primera demo funcional de MLLDE. Los artefactos ya producidos se enlazan en el §3.3.

1. Título

Enseñar lenguas en la era de los LLM — El Mobile Language Learning Design Environment (MLLDE): un marco ético de diseño y medición, con alfabetización en IA, para apps de lenguas mobile-native, que desarrolla la escritura y el habla.

2. Resumen

Los grandes modelos de lenguaje (LLM) han cambiado la forma en que las personas escriben, hablan y aprenden lenguas, y el smartphone es hoy el principal medio del estudio informal de idiomas. Sin embargo, las apps de lenguas priorizan las rachas por encima de la capacidad de actuar en la lengua; el texto académico generado por LLM es estructuralmente fluido pero interpersonalmente plano (escasa toma de postura, implicación y automención), de modo que quien se apoya en él acríticamente corre el riesgo de un registro homogeneizado y sin voz; y la evaluación automática del habla, aunque técnicamente madura, produce evidencias que no pueden intercambiarse ni acumularse entre sistemas. El profesorado posee una pedagogía sólida, pero carece de una vía fundamentada, ética y medible para convertirla en aprendizaje motivador, pensado para el móvil, que además construya la alfabetización en IA del alumnado (una competencia para el estudio y el empleo; ODS 4.3–4.4).

Esta tesis propone y valida empíricamente el **Mobile Language Learning Design Environment (MLLDE)**: un entorno de diseño y medición para aplicaciones de lenguas mobile-native, replicable y anclado en el MCER, que integra la tutoría conversacional responsable con LLM y el diseño curricular, y que trata la alfabetización en IA como un resultado de aprendizaje diseñado. MLLDE plantea dos aportaciones: ① **escritura / alfabetización en IA**, instanciada en Academic Writing Journey (AWJ) —la continuación directa del Objetivo 4 del estudio de corpus del TFM—, que enseña a conservar la agencia retórica frente a la firma estilística de los LLM; y ② **habla / pronunciación**, formada por Architecture Voice Design (una arquitectura anclada en el MCER que extiende el GPT personalizado, basado en lenguaje, *PhD Chema* —cuya primera versión no evalúa la pronunciación— añadiendo la pronunciación como canal evaluado de primer orden mediante ASR/GOP) y un Measurement Module que formaliza la evidencia acústica de pronunciación como un perfil xAPI interoperable y alineado al MCER (IEEE 9274.1.1-2023), con telemetría dual que registra tanto el desempeño del aprendiz como el acto docente de la IA. El Measurement Module sigue un principio **Measure ≠ Decide** —el modelo observa, un motor determinista asigna la banda MCER, de modo que nada en pantalla se inventa— y una **política de honestidad de la evidencia en tres tiers**: Tier 1, una rúbrica MCER sobre la transcripción ASR (ya en producción); Tier 2, puntuación de pronunciación instrumentada (de proveedor); y Tier 3, un modelo propio de Goodness-of-Pronunciation de nivel investigación (la contribución profunda de la tesis) — de modo que ningún informe reclama más precisión que la que el sistema tiene (una destreza no medida muestra «—», nunca un valor inventado). Un prototipo gamificado mobile-native (PWA sin conexión, WCAG-AA, con un mentor de IA que andamia sin dar respuestas) es la primera demo del

entorno. Objetivo general: desarrollar, formalizar y validar MLLDE y sus principios de diseño. Metodología: Investigación Basada en Diseño (DBR), operacionalizada mediante el Successive Approximation Model, con evaluación de métodos mixtos del aprendizaje, las ganancias en alfabetización en IA y en pronunciación, el compromiso y la replicabilidad entre niveles del MCER y lenguas meta.

3. Antecedentes y estado actual

3.1 El problema (tres necesidades convergentes). - **Diseño mobile-native.** El smartphone es la vía principal del estudio informal, pero las apps dominantes privilegian el reconocimiento descontextualizado y las métricas de retención frente a la competencia comunicativa/pragmática; el aprendizaje móvil necesita su propia lógica de diseño y no un e-learning encogido (Clothier, 2026; Kukulska-Hulme y Shield, 2008; Stockwell, 2010; Godwin-Jones, 2011). - **Escritura / alfabetización en IA.** El texto académico de los LLM sobreproduce el andamiaje textual (marcadores lógicos y de encuadre) e infrautiliza los recursos interaccionales (atenuadores, enfatizadores, marcadores de actitud, de compromiso, automención) y fabrica evidenciales (Jiang y Hyland, 2024, 2025a–c; Reinhart et al., 2025; Kobak et al., 2025; Walters y Wilder, 2023). Los detectores son frágiles y sesgados contra escritores no nativos (Liang et al., 2023; Erol et al., 2025); la respuesta responsable es pedagógica, no forense: las universidades que en su día construyeron la alfabetización académica deben ahora construir la alfabetización en IA (Almatrafi et al., 2024; Koltay, 2025; Kong et al., 2023; Cotton et al., 2023). - **Habla / pronunciación.** Las tecnologías de habla con IA (ASR, alineamiento forzado, Goodness-of-Pronunciation; Witt y Young, 2000) pueden puntuar precisión fonémica, fluidez, prosodia e inteligibilidad, y el Volumen Complementario del MCER (Council of Europe, 2020) concibe la pronunciación como competencia fonológica; pero las métricas acústicas, los descriptores del MCER y los estándares de analítica del aprendizaje (xAPI) siguen desconectados, de modo que la evidencia de pronunciación no es interoperable entre tutores inteligentes, LMS y Learning Record Stores. Esta necesidad es impulsada por la industria, no solo teórica: el requisito de un modo de voz/pronunciación medible y basado en xAPI surgió de una solicitud real de un cliente en la práctica profesional de la doctoranda, anclando esta aportación en una demanda real y en la tradición de la DBR de contextos auténticos.

3.2 Estado del arte (por líneas). IA y alfabetización académica (Almatrafi et al., 2024; Koltay, 2025; Kong et al., 2023). Metadiscurso y contraste humano/LLM (Hyland, 2005; Hyland y Tse, 2004; Ädel, 2006; Jiang y Hyland, 2024–2025c). MALL y microaprendizaje (Kukulska-Hulme y Shield, 2008; Stockwell, 2010; Godwin-Jones, 2011; Clothier, 2026). Gamificación, CLIL, enfoque por tareas (Deterding et al., 2011; G-CLIL/IPO de Casañ-Pitarch; Coyle et al., 2010; Harmer, 2007; Johnson, 2002; Crawford, 2001). Cognición, léxico, pragmática (Mayer, 2009; Lewis, 1993; Kasper y Rose, 2001). Evaluación automática de la pronunciación (Witt y Young, 2000; Council of Europe, 2020). Analítica del aprendizaje e interoperabilidad (xAPI / IEEE 9274.1.1-2023; ADL, 2023). IA responsable y regulación (Reglamento de IA de la UE, art. 50; Ley Europea de Accesibilidad; RGPD; DUA/CAST).

Vacío de síntesis. Estas líneas rara vez se integran en un único método mobile-native construido para el aprendizaje de lenguas con alfabetización en IA, creable por el profesorado y medible mediante analítica interoperable, tanto para la escritura como para el habla. MLLDE cubre este vacío.

3.3 Resultados previos del equipo y de la doctoranda. El Departamento de Lingüística Aplicada de la UPV aporta la base científica directa: el trabajo de la Prof.^a Carrió-Pastor sobre metadiscurso y la herramienta de etiquetado METOOL (Carrió-Pastor, 2020), y el del Prof. Casañ-Pitarch sobre Gamified-CLIL, el modelo Input–Processing–Output (IPO) y los LLM en la enseñanza de lenguas. Sobre esta base, la doctoranda ya ha producido, y puesto en abierto, un linaje de integración funcional — Academic Writing Journey (primer modelo) → un prototipo mobile-native → MLLDE (el método generalizado):

Artefacto	Etapas en MLLDE	Enlace
TFM — metadiscurso en abstracts de TFM	Base empírica (aportación ①)	[RiuNet — pendiente]
Academic Writing Journey — diseño instruccional (Canva)	Diseño	https://profeanaeslava.my.canva.site/academicwritingjourney
Academic Writing Journey — curso gamificado en HTML	Primera implementación	https://profeanaeslavaedtech.github.io/Gamification/

Artefacto	Etapas en MLLDE	Enlace
The Abstract Heist — módulo escape-room	Evaluación gamificada	https://profeanaeslavaedtech.github.io/escaperoom/
Abstract Generator / prototipo alojado (UPV)	Herramienta de la fase Output	https://personales.alumno.upv.es/aeslgra/
Libro de datos interactivo del corpus (metadiscursos)	Visualización de datos	https://profeanaeslavaedtech.github.io/portofolio/metadi-scource-visualization.html
Prototipo gamificado mobile-native (demo MLLDE)	Primera demo mobile-native	[prototipo privado]

El AWJ fue evaluado de forma independiente con un **10/10 en diseño eLearning inclusivo** por la UPV (2026) con cero errores de navegación del alumnado, y demostró ser agnóstico de plataforma (reconstruido de Canva → Articulate 360 Rise, SCORM/xAPI; desplegado en cuatro familias de LMS). El AWJ ya integra al tutor GPT personalizado *PhD Chema* —un agente conversacional basado en lenguaje— en los seis niveles; su primera versión no evalúa la pronunciación acústicamente, que es justamente el vacío que cubren el Architecture Voice Design y el Measurement Module acústico del doctorado. Un prototipo gamificado mobile-native —PWA sin conexión, WCAG-AA, con un mentor de IA que andamia sin dar respuestas (bajo consentimiento explícito; nunca hace la tarea del aprendiz)— se ha construido como demo funcional que evidencia que la fase Output del modelo IPO (Casañ-Pitarch) es viable en el móvil.

Además, el Measurement Module ya está **vivo en una instancia de producción aplicada: TK Coach («Capi», Talketika)**, un tutor de inglés de negocios por voz, ejecuta el **Tier 1** de extremo a extremo — tres agentes LLM que observan (tutor · corrector · evaluador) más un **consolidador de código determinista** (no un 4.º LLM) que computa la banda MCER 0–10 y emite una sola sentencia xAPI a un LRS conformante (Veracity), bajo una **puerta acústica** (los turnos por debajo de 0.70 de confianza ASR se registran como incidentes, nunca puntúan) y con separación estricta de un **flujo de medición** (una vez por sesión) y un **flujo de pedagogía** (por turno, que nunca puntúa). Esto aporta evidencia real de viabilidad de la aportación de habla antes del estudio de inglés académico, y es el caso en el que se desarrollan los tres tiers de evidencia.

El modelo de gobernanza humano/IA del proyecto —el humano posee la pedagogía, la IA ejecuta bajo revisión— está formalizado en un High-Level Design (HDD), un artefacto de Arquitectura de Experiencias de Aprendizaje altamente evaluado que evidencia competencia de diseño instruccional de nivel profesional (accesibilidad, medición, modularidad, riesgos/traspaso) y ancla la capa de GOBERNANZA del entorno.

La doctoranda aporta más de 20 años en educación de lenguas y diseño instruccional a nivel universitario y de bachillerato — un título de Licenciatura en Docencia y Educación (Inglés), Summa Cum Laude, con especialización en currículo, primera de su promoción (18,975/20 — equivalente a 9,07/10 en la escala española) — Universidad de Los Andes, Mérida, Venezuela (2004) — y un Máster en Lenguas y Tecnología (UPV, nota media 9,4) — un proyecto de fin de grado con mención honorífica publicado en una revista indexada (Eslava-Graterol, 2005, Kaleidoscopio, 2(3), 51–56; ISSN 1690-6054; indexada en CLASE, UNAM), credenciales profesionales de diseño instruccional (UC Irvine, 2025; University of Cambridge, 2025) y un agradecimiento en un artículo Elsevier con revisión por pares por «valuable comments on the manuscript's English and scientific content» (Sotelo-Casas et al., 2019; agradecida como A. Z. Eslava de Morales) — situando la Investigación Basada en Diseño en contextos auténticos de enseñanza y de escritura científica.

3.4 Punto de partida — el marco MLLDE propuesto. MLLDE anida marcos consolidados; la síntesis, orientada a la entrega mobile-native, es la aportación, y cada marco se atribuye a su autor.

MLLDE – Mobile Language Learning Design Environment (mobile-native)

└ DISEÑO SAM → G-CLIL/IP0 (Casañ-Pitarch) → 4Cs → ESA → CTL/REACT → UX móvil + doble codificación

└ ALFAB. EN IA Hyland (2005) base de metadiscursos → firma humano-vs-LLM → agencia retórica [1]

└ TUTORÍA Architecture Voice Design: mentor GPT basado en lenguaje 'PhD Chema' +

NUEVO canal

| acústico de pronunciación como canal evaluado de primer orden · pragmática
· enfoque léxico
└ MEDICIÓN Measurement Module (Measure≠Decide; 3 tiers de evidencia) – ESCRITURA
(METOOL/Hyland) + HABLA (ASR·GOP)
| → MCER → xAPI (IEEE 9274.1.1-2023) → LRS; motor determinista; la
telemetría dual registra el acto docente de la IA
└ GOBERNANZA Reglamento IA UE (art. 50 + registro) · LEA/WCAG · RGPD desde el diseño ·
DUA – el humano posee la pedagogía

4. Bibliografía

(Las referencias se citan en su lengua original, conforme a APA 7.^a ed. Las citadas en el §3.)

- Ädel, A. (2006). *Metadiscourse in L1 and L2 English*. John Benjamins. <https://doi.org/10.1075/scl.24>
- Allen, M. W., & Sites, R. (2012). *Leaving ADDIE for SAM: An agile model for developing the best learning experiences*. ASTD Press.
- Almatrafi, O., Johri, A., & Lee, H. (2024). A systematic review of AI literacy conceptualization, constructs, and implementation and assessment efforts (2019–2023). *Computers and Education Open*, 6, Article 100173. <https://doi.org/10.1016/j.caeo.2024.100173>
- Anderson, T., & Shattuck, J. (2012). Design-based research: A decade of progress in education research. *Educational Researcher*, 41(1), 16–25. <https://doi.org/10.3102/0013189X11428813>
- Carrió-Pastor, M. L. (2020). Conocer la lengua a través de los corpus: La herramienta METOOL, retos para el análisis de los marcadores discursivos. *Pragmalingüística*, 28, 255–274. <https://doi.org/10.25267/Pragmalinguistica.2020.i28.13>
- Casañ-Pitarch, R. (2017). Gamifying content and language integrated learning with serious videogames. *Journal of Language and Education*, 3(3), 107–114. <https://doi.org/10.17323/2411-7390-2017-3-3-107-114>
- Clothier, P. (2026). *Mastering mobile learning design*. Routledge.
- Cotton, D. R. E., Cotton, P. A., & Shipway, J. R. (2023). Chatting and cheating: Ensuring academic integrity in the era of ChatGPT. *Innovations in Education and Teaching International*, 61(2), 228–239. <https://doi.org/10.1080/14703297.2023.2190148>
- Council of Europe. (2020). *Common European Framework of Reference for Languages: Learning, teaching, assessment — Companion volume*. Council of Europe Publishing.
- Coyle, D., Hood, P., & Marsh, D. (2010). *CLIL: Content and language integrated learning*. Cambridge University Press.
- Crawford, M. L. (2001). *Teaching contextually: Research, rationale, and techniques for improving student motivation and achievement in mathematics and science*. CCI Publishing.
- Deterding, S., Dixon, D., Khaled, R., & Nacke, L. (2011). From game design elements to gamefulness: Defining "gamification." In *Proceedings of the 15th International Academic MindTrek Conference* (pp. 9–15). ACM. <https://doi.org/10.1145/2181037.2181040>
- Erol, G., Ergen, A., Gülşen Erol, B., Kaya Ergen, Ş., Bora, T. S., Çölgeçen, A. D., Araz, B., Şahin, C., Bostancı, G., Kılıç, İ., Macit, Z. B., Sevgi, U. T., & Güngör, A. (2025). Can we trust academic AI detective? Accuracy and limitations of AI-output detectors. *Acta Neurochirurgica*, 167(1), Article 214. <https://doi.org/10.1007/s00701-025-06622-4>
- Godwin-Jones, R. (2011). Emerging technologies: Mobile apps for language learning. *Language Learning & Technology*, 15(2), 2–11.
- Harmer, J. (2007). *The practice of English language teaching* (4th ed.). Pearson Longman.
- Hyland, K. (2005). *Metadiscourse: Exploring interaction in writing*. Continuum.
- Hyland, K., & Tse, P. (2004). Metadiscourse in academic writing: A reappraisal. *Applied Linguistics*, 25(2), 156–177. <https://doi.org/10.1093/applin/25.2.156>
- Institute of Electrical and Electronics Engineers. (2023). *IEEE standard for learning technology — JSON data model format and RESTful web service for learner experience data tracking and access* (IEEE Std 9274.1.1-

2023). IEEE. <https://ieeexplore.ieee.org/document/10273185>

- Jiang, F., & Hyland, K. (2024). Does ChatGPT argue like students? Bundles in argumentative essays. *Applied Linguistics*, 46(3), 375–391. <https://doi.org/10.1093/applin/amae052>
- Jiang, F., & Hyland, K. (2025a). Rhetorical distinctions: Comparing metadiscourse in essays by ChatGPT and students. *English for Specific Purposes*, 79, 17–29. <https://doi.org/10.1016/j.esp.2025.03.001>
- Jiang, F., & Hyland, K. (2025b). Does ChatGPT write like a student? Engagement markers in argumentative essays. *Written Communication*, 42(3), 463–492. <https://doi.org/10.1177/07410883251328311>
- Jiang, F., & Hyland, K. (2025c). Metadiscursive nouns in academic argument: ChatGPT vs student practices. *Journal of English for Academic Purposes*, 75, Article 101514. <https://doi.org/10.1016/j.jeap.2025.101514>
- Johnson, E. B. (2002). *Contextual teaching and learning: What it is and why it's here to stay*. Corwin Press.
- Kasper, G., & Rose, K. R. (2001). *Pragmatics in language teaching*. Cambridge University Press.
- Kobak, D., González-Márquez, R., Horvát, E.-Á., & Lause, J. (2025). Delving into LLM-assisted writing in biomedical publications through excess vocabulary. *Science Advances*, 11(27), Article eadt3813. <https://doi.org/10.1126/sciadv.adt3813>
- Koltay, T. (2025). Some issues of data literacy and AI literacy in the library. *Knižnica*, 2025(2), 11–17.
- Kong, S.-C., Cheung, W. M.-Y., & Zhang, G. (2023). Evaluation of an artificial intelligence literacy course for university students with diverse study backgrounds. *Educational Technology & Society*, 26(1), 16–30.
- Kukulska-Hulme, A., & Shield, L. (2008). An overview of mobile assisted language learning: From content delivery to supported collaboration and interaction. *ReCALL*, 20(3), 271–289. <https://doi.org/10.1017/S0958344008000335>
- Lewis, M. (1993). *The lexical approach: The state of ELT and a way forward*. Language Teaching Publications.
- Liang, W., Yuksekgonul, M., Mao, Y., Wu, E., & Zou, J. (2023). GPT detectors are biased against non-native English writers. *Patterns*, 4(7), Article 100779. <https://doi.org/10.1016/j.patter.2023.100779>
- Mayer, R. E. (2009). *Multimedia learning* (2nd ed.). Cambridge University Press. <https://doi.org/10.1017/CBO9780511811678>
- Reinhart, A., Markey, B., Laudénbach, M., Pantusen, K., Yurko, R., Weinberg, G., & Brown, D. (2025). Do LLMs write like humans? Variation in grammatical and rhetorical styles. *Proceedings of the National Academy of Sciences*, 122(8), Article e2422455122. <https://doi.org/10.1073/pnas.2422455122>
- Sotelo-Casas, R. C., Rodríguez-Troncoso, A. P., Rodríguez-Zaragoza, F. A., Solís-Marín, F. A., Godínez-Domínguez, E., & Cupul-Magaña, A. L. (2019). Spatial-temporal variations in echinoderm diversity within coral communities in a transitional region of the northeast of the eastern Pacific. *Estuarine, Coastal and Shelf Science*, 227, Article 106346. <https://doi.org/10.1016/j.ecss.2019.106346>
- Stockwell, G. (2010). Using mobile phones for vocabulary activities: Examining the effect of the platform. *Language Learning & Technology*, 14(2), 95–110.
- Walters, W. H., & Wilder, E. I. (2023). Fabrication and errors in the bibliographic citations generated by ChatGPT. *Scientific Reports*, 13, Article 14045. <https://doi.org/10.1038/s41598-023-41032-5>
- Witt, S. M., & Young, S. J. (2000). Phone-level pronunciation scoring and assessment for interactive language learning. *Speech Communication*, 30(2–3), 95–108. [https://doi.org/10.1016/S0167-6393\(99\)00044-8](https://doi.org/10.1016/S0167-6393(99)00044-8)

Añadidas — medición de voz, feedback y evaluación de la formación: - International Phonetic Association. (1999). *Handbook of the International Phonetic Association*. Cambridge University Press. - Kirkpatrick, J. D., & Kirkpatrick, W. K. (2016). *Kirkpatrick's four levels of training evaluation*. ATD Press. - Krashen, S. D. (1985). *The input hypothesis: Issues and implications*. Longman. - Phillips, J. J., & Phillips, P. P. (2016). *Handbook of training evaluation and measurement methods* (4.ª ed.). Routledge. - Schmidt, R. W. (1990). The role of consciousness in second language learning. *Applied Linguistics*, 11(2), 129–158. <https://doi.org/10.1093/applin/11.2.129>

Nota. Entradas verificadas contra la lista de referencias del TFM (aparato de metadiscorso/alfabetización en IA) y catálogos públicos. Un pequeño número de libros/normas (Coyle et al., 2010; Kasper y Rose, 2001; IEEE 9274.1.1-2023) no tiene DOI asignado y se cita por editorial/URL conforme a APA 7.ª ed.

5. Hipótesis y objetivos

Justificación e hipótesis de partida. Dado que el texto de los LLM reproduce el andamiaje de la lengua a la vez que aplanla la dimensión interpersonal (escritura), y que la evidencia de pronunciación con IA no es interoperable (habla), un único entorno mobile-native, éticamente gobernado y creable por el profesorado puede (a) construir la alfabetización en IA y la agencia retórica del alumnado y (b) hacer medible el habla en términos interoperables y anclados al MCER. **Hipótesis de partida:** una intervención mobile-native diseñada con MLLDE mejora la competencia de escritura crítica con IA y produce evidencia de pronunciación válida e interoperable de forma más eficaz que las condiciones de base no integradas.

Objetivo general. Desarrollar, formalizar y validar empíricamente MLLDE como entorno ético de diseño y medición, con alfabetización en IA, para aplicaciones de lenguas mobile-native.

Objetivos específicos (realistas para la duración de la tesis). 1. Formalizar MLLDE — constructos, capas (diseño · tutoría · medición · gobernanza) y el esquema de autoría mobile-native para un **currículo que integra la escritura y la modalidad de habla / voz**, cada una con su medición anclada. 2. Instanciar/refinar Academic Writing Journey (AWJ) — aportación ① — extendiendo el Objetivo 4 del TFM (perfiles de corpus → materiales de alfabetización en IA), llevado a mobile-native. 3. Refinar el prototipo gamificado mobile-native como primera demo de MLLDE (autoría engine + data). 4. Ejecutar el piloto del AWJ con medidas de metadiscursio pre/post (la cuarta línea de investigación futura del TFM). 5. Aportación ② — habla: construir el Architecture Voice Design — extender el agente GPT personalizado, basado en lenguaje, *PhD Chema* con un canal acústico de pronunciación (ASR/GOP) del que carece su primera versión — y el Measurement Module — un perfil xAPI alineado al MCER (identificadores persistentes, vocabulario controlado, correspondencias acústica ↔ MCER, interpretación pedagógica, registros interoperables; telemetría dual que registra el acto docente de la IA). Desarrollar la medición de la pronunciación en **tres tiers de evidencia** — Tier 1 (rúbrica sobre ASR, en producción), Tier 2 (puntuación instrumentada de proveedor), Tier 3 (GOP a medida con inventario IPA por nivel) — bajo un motor **Measure ≠ Decide** y una política de honestidad de la evidencia (inteligibilidad, no acento nativo). 6. Aislar mecanismos (ejercicios humano-vs-LLM; andamiaje de IA sin dar respuestas; pistas animadas). 7. Probar la replicabilidad entre niveles/destinos/lenguas (esfuerzo de diseño + fidelidad). 8. Producir directrices de diseño, un método de autoría para el profesorado y un modelo de gobernanza de IA responsable.

Preguntas de investigación e hipótesis. - **PI1 (diseño).** ¿Qué principios constituyen un MLLDE mobile-native eficaz para la escritura y el habla? - **PI2 (escritura).** ¿Cómo afecta el AWJ al control del metadiscursio y a la escritura crítica con IA frente a una condición de base? — **H1:** mayores ganancias pre/post en metadiscursio interpersonal y en la discriminación humano-vs-LLM. - **PI3 (mecanismos).** ¿Efectos de los ejercicios humano-vs-LLM, el andamiaje sin dar respuestas y las pistas animadas? — **H2:** el andamiaje sin dar respuestas aumenta la producción del aprendiz; **H3:** las pistas animadas con imagen mejoran el recuerdo / reducen la carga cognitiva. - **PI4 (habla, por tiers).** ¿Puede formalizarse la evidencia de voz/acústica como un perfil xAPI válido, interoperable y alineado al MCER en **tres tiers de evidencia** (rúbrica-sobre-ASR → instrumentado → GOP a medida), y qué gana la validez en cada tier? ¿Cuál es el **piso de inteligibilidad** defendible por tier? — **H4:** las puntuaciones acústicas mapeadas por xAPI concuerdan con valoraciones expertas del MCER y mejoran frente a una condición sin retroalimentación; cada tier añade señal sin romper el anterior. - **PI4b (validez de la medición y honestidad como método).** ¿Una rúbrica MCER aplicada por un LLM sobre la transcripción ASR (Tier 1) produce bandas que **concuerdan con jueces humanos expertos** y son **estables según el tamaño del modelo**; y la **política de honestidad** —un **motor determinista** (no un LLM) asigna la banda, cada afirmación declara su tier, las destrezas no medidas muestran «—» y todas las superficies se unifican sobre una sola verdad (LRS)— evita el sobre-reclamo y las puntuaciones alucinadas? — **H6:** el acuerdo LLM–humano en Tier 1 es aceptable y estable, y la unificación de superficies resiste la alucinación. - **PI5 (transferibilidad).** ¿Es MLLDE replicable entre implementaciones, niveles del MCER y lenguas? — **H5:** un motor compartido crea nuevas instancias con menor esfuerzo y fidelidad preservada.

6. Metodología a utilizar

Enfoque. Investigación Basada en Diseño (Anderson y Shattuck, 2012) con ciclos de construcción según el Successive Approximation Model (Allen y Sites, 2012: Preparación → Alfa → Beta → Gold), ya empleado en el

AWJ y el prototipo mobile-native. Tareas y resultados previstos:

Tarea	Actividad	Resultado previsto
T1	Formalizar MLLDE; validación experta (Delphi) del marco, el esquema mobile-native y el perfil xAPI	Marco + esquema validados
T2	Refinar el AWJ y el prototipo mobile-native — incluidos los Niveles 5 y 6 del AWJ (Output: escritura y habla/conference pitch) reconstruidos en entorno mobile-native como sede del módulo acústico	Prototipos gold mobile-native
T3	Piloto del AWJ: medidas de metadiscursio pre/post + tarea humano-vs-LLM	Datos de resultado en escritura/alfabetización en IA
T4	Experimentos de mecanismo (andamiaje; pistas)	Evidencia causal de mecanismos
T5	Extender el mentor basado en lenguaje <i>PhD Chema</i> con un canal acústico de pronunciación (ASR/GOP) + construir el Measurement Module sobre los Niveles 5–6 del AWJ mobile-native; validar el xAPI acústico frente a valoraciones expertas del MCER	Evidencia de pronunciación interoperable
T6	Replicación: nuevos niveles/destinos/lenguas; interoperabilidad con LRS	Datos de replicabilidad + fidelidad
T7	Síntesis; directrices; método de autoría; modelo de gobernanza	Principios de diseño + tesis

Participantes y reclutamiento. La muestra principal es **alumnado adulto de inglés académico (B2 → C1)** —la población para la que se diseñó el AWJ—, reclutada de una cohorte amplia y ya disponible (~300 aprendices al año) a través del codirector, Prof. Casañ-Pitarch, lo que ofrece un grupo ecológicamente válido y con potencia suficiente para el piloto de escritura / alfabetización en IA (T3) y para la **aplicación mobile-native de inglés académico** —el AWJ llevado a mobile-native, con un **modo voz y un sistema de evaluación integrado**— que aloja el módulo de habla / pronunciación (**Architecture Voice Design** + el **Measurement Module**: evaluación de pronunciación alineada al MCER en xAPI; T5). Durante el doctorado, esta app mobile-native de inglés académico —modo voz **más** su sistema de evaluación— es el artefacto principal que se construye y se evalúa. El **estudio de replicación (T6)** extiende después el método al **español** (A1–A2, vía el prototipo móvil *Language Passport*) y a otros niveles del MCER y lenguas, probando la transferibilidad entre lenguas. El tamaño y el muestreo, así como el reclutamiento de una cohorte de español vía los servicios de idiomas de la UPV, se finalizarán con la dirección y el comité de ética.

El Measurement Module y los tres tiers de evidencia. La evidencia de habla se desarrolla bajo una arquitectura **Measure ≠ Decide**: tres agentes LLM que observan describen la interacción mientras un **motor determinista** (código, no un 4.º LLM) computa la banda MCER 0–10 ($\text{Global} \times 5 + \text{analíticas} \times 2 \div \text{pool} \times 10$) y emite una sola sentencia xAPI; un **flujo de medición** (una vez por sesión) queda aislado por cortafuegos de un **flujo de pedagogía** (por turno, que nunca puntúa). La pronunciación se construye en tres tiers — **Tier 1** rúbrica MCER sobre la transcripción ASR (en producción), **Tier 2** puntuación de pronunciación instrumentada de proveedor (p. ej. Azure Pronunciation Assessment), **Tier 3** un modelo propio de Goodness-of-Pronunciation con **inventario IPA por nivel** (Witt & Young, 2000) — cada uno declarando su `measure_model` para comparabilidad y regido por una **política de honestidad de la evidencia**: una afirmación nunca excede la precisión de su tier, las destrezas no medidas muestran «—», las variantes aceptadas (p. ej. *seseo/distinción*) nunca bajan una puntuación (IPA, 1999), y una **puerta acústica** (confianza ASR 0.70) convierte los turnos de baja confianza en incidentes que no puntúan. El feedback se dosifica con una **escala de noticing (0–4)** ajustada al nivel MCER (modelar A2–B1, elicitar B2+; Schmidt, 1990) dentro de una lógica *i+1* (Krashen, 1985).

Estudio de validez del Tier 1. Las bandas de la rúbrica-LLM se contrastan con **valoraciones humanas expertas** (acuerdo), su **estabilidad test–retest** y su **sensibilidad al tamaño del modelo**; una **auditoría de integridad** (revisión por paneles + agentes, con un «H0 watchdog» que marca cualquier descriptor pintado como banda)

verifica que ninguna superficie sobre-reclama. Los informes por actor (alumno · profesor · RR.HH.) usan un marco de evaluación **Kirkpatrick / Phillips**, con alineación **ESCO** opcional.

Instrumentos y datos. *Escritura:* rúbrica de escritura del MCER; medidas de metadiscursio pre/post basadas en METOOL (Carrió-Pastor, 2020); tarea de discriminación humano-vs-LLM. *Habla:* medidas acústicas (precisión fonémica, acento, ritmo, entonación, velocidad de habla, fluidez, inteligibilidad) vía ASR/GOP, mapeadas por el perfil xAPI y validadas frente a valoraciones expertas de competencia fonológica del MCER. *Comunes:* escalas de autoeficacia/motivación; telemetría de la app + sentencias xAPI (telemetría dual: desempeño del aprendiz + acto docente de la IA); System Usability Scale; medidas de carga cognitiva; entrevistas, protocolos de pensamiento en voz alta, revisiones de expertos. *Análisis:* métodos mixtos — estadística inferencial (pre/post, entre condiciones) triangulada con análisis temático.

Evaluación crítica de dificultades y plan de contingencia. (i) Etiquetado por un solo codificador (limitación del TFM) → fiabilidad interjueces y comprobaciones test–retest. (ii) Reclutamiento/tamaño muestral → programas asociados; diseños intrasujeto; criterios de éxito preregistrados. (iii) Fiabilidad del mentor de IA → prompts restringidos que no dan respuestas; revisión humana; la IA como apoyo, no como único punto de fallo. (iv) Riesgo de interoperabilidad xAPI/LRS → adoptar la norma consolidada IEEE 9274.1.1-2023; validación experta antes de escalar. (v) Ética/regulación → RGPD desde el diseño (seudonimizado, en cliente cuando sea posible), Reglamento de IA de la UE (art. 50: transparencia + registro/supervisión humana), accesibilidad LEA/WCAG; aprobación del comité de ética de la UPV antes de la recogida de datos.

7. Medios a utilizar

Biblioteca y bases de datos de la UPV; el etiquetador METOOL (Carrió-Pastor, 2020) y el corpus/flujo de trabajo del TFM; prototipos mobile-native existentes (AWJ y un prototipo móvil gamificado) y conjunto de herramientas de diseño (Canva, Articulate 360 Rise, HTML/PWA); tutores conversacionales LLM (p. ej. Claude de Anthropic y otros modelos de la familia GPT) — el recurso central de alfabetización en IA, que impulsa el mentor conversacional basado en lenguaje *PhD Chema* (un GPT personalizado), el andamiaje sin dar respuestas y los ejercicios de comparación humano-vs-LLM, usados bajo el modelo de gobernanza de IA responsable; herramientas de evaluación del habla ASR/GOP y captura de audio en dispositivos móviles; un Learning Record Store conformante (Veracity) para registros y paneles xAPI (IEEE 9274.1.1-2023), más un servicio de evaluación de pronunciación de proveedor (p. ej. Azure) para el tier instrumentado; software estadístico (p. ej. R/JASP) y de análisis cualitativo; acceso a cohortes de aprendices vía servicios de idiomas de la UPV / programas asociados. No se requiere equipamiento especializado más allá de dispositivos móviles.

8. Planificación temporal y utilidad de la investigación

Cronograma (vinculado a las tareas del §6).

Año	Tareas	Hitos
1	T1–T2	Artículo de marco; esquema mobile-native validado; perfil xAPI v1; aprobación ética
2	T3–T5	Artículos de resultados + mecanismos; resultados del piloto AWJ; validación del xAPI acústico
3	T6–T7	Artículos de replicabilidad + interoperabilidad; directrices; tesis; defensa

(La modalidad a tiempo parcial extiende esto a ~5 años.)

Hoja de ruta de medición (tiers de evidencia). **Tier 1** — en producción y verificado (LRS vivo; medición interina en un modelo pequeño, declarada por sesión). **Tier 2** — planificado: integrar evaluación de pronunciación de proveedor para encender la banda de Pronunciación (hoy «—»). **Tier 3** — investigación: inventario IPA por nivel + modelo GOP a medida (la contribución fonémica del PhD). *Transversal:* validar el uptake del noticing y la fiabilidad del scoring rúbrica-LLM según el tamaño del modelo.

Utilidad e impacto. Esta investigación se sitúa en el cruce de cuatro campos — **IA en educación** (alfabetización en IA como resultado diseñado), **evaluación de lenguas** (medición anclada al MCER e interoperable en xAPI, de escritura y habla), **PLN aplicado / interacción persona–IA** (un tutor conversacional con andamiaje responsable) e

IA responsable (transparencia del art. 50, supervisión humana y RGPD desde el diseño); su aportación es integrarlos en un único entorno medible y creable por el profesorado. *Científico*: un marco de entorno mobile-native, principios de diseño empíricamente fundamentados y un perfil xAPI alineado al MCER que porta evidencia tanto de metadiscurso (escritura) como acústica (habla) — contribuyendo a la investigación en alfabetización en IA, metadiscurso/EAP, MALL, CLIL y analítica del aprendizaje (difusión nacional e internacional). *Social/educativo*: competencias de escritura y habla críticas con IA que apoyan el acceso equitativo a una educación superior de calidad y la empleabilidad (ODS 4.3–4.4), en un formato accesible, creable por el profesorado y pensado para el móvil. *Económico/técnico*: un modelo de autoría engine + data que permite al profesorado construir lecciones mobile-native sin programar, y registros de aprendizaje interoperables reutilizables entre LMS/LRS.

9. Plan de formación

- **Cursos transversales/metodológicos**: metodología de investigación, estadística para lingüística, herramientas de corpus, analítica del aprendizaje/xAPI, ética de la investigación y ciencia abierta (Escuela de Doctorado de la UPV).
- **Seminarios de especialidad**: lingüística aplicada, CALL/MALL, gamificación, IA generativa en educación (bajo la dirección del profesorado supervisor).
- **Congresos (difusión)**: p. ej. EUROCALL, EATAW, AESLA y foros de lingüística aplicada / EdTech — uno por año.
- **Movilidad**: una estancia de investigación en un grupo internacional de CALL / analítica del aprendizaje / evaluación de la pronunciación.
- **Publicaciones**: artículo de marco (año 1); artículos de resultados/mecanismos y de xAPI acústico (año 2); artículo de replicabilidad/interoperabilidad (año 3).

Este plan se desarrolla bajo la dirección de la Prof.^a M^a Luisa Carrió-Pastor —por su inestimable aportación al ámbito científico y a la lingüística aplicada— y la codirección del Prof. Ricardo Casañ-Pitarch, para continuar, a través de sus publicaciones sobre LLM, la integración responsable de los LLM en la enseñanza de lenguas. Para su presentación al Departamento de Lingüística Aplicada, Universitat Politècnica de València.

Nota de transparencia: Elaborado con asistencia de IA generativa. Revisado, editado y aprobado bajo la responsabilidad editorial de Ana Eslava-Graterol, diseñadora instruccional y profesional autónoma registrada en España (Reglamento (UE) 2024/1689 — Ley de IA, art. 50 — voluntario; material de autoría y verificación humanas).

© 2026 Ana Eslava-Graterol. MLLDE.